

研究展示：统计与机器学习方法在部署 ML 系统中的应用

阮鹤樵

2026 年 9 月 17 日

本章概览

- 1 研究目标
- 2 方法概论
- 3 落地场景及生产价值
- 4 未来方向与应用场景

研究目标

本研究旨在面向已部署的机器学习 (ML) 系统，开发严谨、计算高效且可泛化的统计与机器学习方法，以监测，解读和使得模型适应数据分布变化，**保证模型持续产生经济效益，并对指标的异动进行多模态，实时，高效的归因。**核心科学与实践问题包括：

- 给定现有数据 $D_{\text{exist}} = (\mathbf{X}_{\text{exist}}, Y_{\text{exist}})$ 与新数据 $D_{\text{new}} = (\mathbf{X}_{\text{new}}, Y_{\text{new}})$ ，如何判别其分布差异主要源于概念漂移 $P(Y|\mathbf{X})$ 还是协变量偏移 $P(\mathbf{X})$ ？是否能够将这两种变动进行解耦？
- 如何在特征、图像区域或 token 粒度上理解数据变化？能否通过特征选择与子集归因，实现实时或准实时的特征级变化归因？
- 检测出模型性能衰减后，应采取何种方案对模型进行调整以降低模型性能的衰减程度？
- 对于生产中已部署的 ML 模型，如何确定其更新时机与更新策略？
- 如何对分布外 (OOD) 样本进行科学的不确定性估计与评估？
- 如何在线监控特征重要性及其效力衰减？

统计与机器学习方法为分布漂移的检测与适应 (adaptation) 提供支撑。
典型落地场景包括：

- 大模型数据分布与审核逻辑对齐
- 在线模型与特征监控
- 特征库与指标异动的归因分析
- 模型性能衰减的应对策略与可执行洞察 (actionable insights)
- 潜在方向：多模态连续学习
- 潜在方向：智能体推理流畅性检测

本章概览

- ① 研究目标
- ② 方法概论
- ③ 落地场景及生产价值
- ④ 未来方向与应用场景

Overall Roadmap for Research: Testing, Understanding and Adapting Distribution Shift




图: 我们已开发的统计/机器学习方法论概览

方法一：置换检验比较随机森林误差

使用置换检验 (permutation test) 比较随机森林中的验证误差（袋外误差）和测试误差（预测误差）。

- 随机森林以其在多种不同场景下的鲁棒性著称，是隔离分布外（OOD）影响的最佳选择。它能够同时刻画**概念漂移**和**协变量偏移**——得益于随机森林的密度感知特性。
- 只要验证集定义良好，该方法可推广到任意数据模态的任意机器学习模型 - 从嵌入和表征层面。软件开源地址：
<https://github.com/ruanhq-StatsML/RFPerm>
- 随机森林置换检验计算高效、鲁棒性高，能在小样本（ $n=50$ ）下稳定推断。可支撑数据标注校验、跨源特征对齐及 A/B 测试冷启决策。

方法二：元学习器 (Meta-Learner) 检测分布偏移

Meta-Learner as Distance-Estimator 框架

利用因果推断方法（元学习器），通过变量重要性检测分布偏移。以 D_{exist} 为对照组 ($T = 0$)， D_{new} 为实验组 ($T = 1$)。

- 对因果元学习器施加置换检验并重拟合，量化 LOCO 或 Permutation 框架下的变量重要性。该重要性可解释为各变量对特定类型分布偏移的贡献度；该元学习器本质可视为距离估计器。
- 软件开源地址：https://github.com/ruanhq-StatsML/Causal_Objective_Permutation_Test

分布偏移的特征选择

- 给定两批数据，如何确定哪些特征解释了分布偏移？该问题可归结为分布偏移（包括协变量偏移与概念漂移）下的特征选择问题。对于协变量偏移，现有方法较为丰富；对于概念漂移，现有方法仍相对匮乏。
- 我们采用元学习器（因果元学习器、R-learner、DR-learner 以及 causal forest）对概念漂移进行统计检验与特征选择。

协变量偏移的特征选择

我们旨在理解 $P(\mathbf{X}_{\text{exist}})$ 与 $P(\mathbf{X}_{\text{new}})$ 之间的差异——哪些特征子集对协变量偏移有显著贡献？

- **MMD-LOCO**: 最大均值差异 (MMD) 结合留一协变量 (leave-one-covariate-out) 程序, 以差异值作为特征选择的排序依据。
- **RF-领域分类器**: 训练二元分类器以区分两个数据集 $\mathbf{X}_{\text{exist}}$ 与 $\mathbf{X}_{\text{new}}$, 借鉴 C2ST (分类器双样本检验) 思想, 将变量重要性排名作为特征选择标准。基于随机森林的程序与现有 SOTA 方法 (如 **FSL-Net**) 相比极具竞争力。

概念漂移的特征选择

我们旨在理解 $P(Y_{new}|\mathbf{X}_{exist})$ 与 $P(Y_{exist}|\mathbf{X}_{new})$ 之间的差异——哪些特征子集对协变量偏移有显著贡献？

- 对于概念漂移，可利用因果推断方法，包括 **permuCATE** 和 **因果森林分裂程序**（最简约、相对高效），在实践中均有推荐。
- 元学习器（meta-learner）方法旨在检验条件均值 $E[Y | X, T = 1]$ 与 $E[Y | X, T = 0]$ 的等价性。数值研究与实际数据分析均表明，因果推断方法在多种数据类型上具有 SOTA 性能。
- 软件开源地址：https://github.com/ruanhq-StatsML/FSDS-FeatureSelection_for_DistributionShift

分布外特征重要性 (OOD Variable Importance)

- 我们基于元学习器 (meta-learner) 中的伪结果风险 (pseudo-outcome risk), 量化分布外数据与分布内数据之间的距离 (Meta-Learner as Distance Estimator)。
- 采用留一协变量法 (leave-one-covariate-out) 与置换方法 (permutation variable importance) 在元学习框架下估计特征重要性。
- 实证研究与数据应用均表明, 该方法在协变量偏移与概念漂移下均能稳定工作, 能够可靠地识别出 OOD 的关键特征方向。
- 所得重要性评分为特征选择和变量排序提供了直接、可操作的指导。

分布偏移精准定位 (localization)

基于上述方法的检测结果，我们进一步将分布偏移定位到由关键特征所划分的子集层面 (post-hoc subset localization procedure)。需要指出，分布漂移、协变量偏移与模型性能之间在统计上无法完全解耦。因此，在观测到模型性能衰减后，更务实的策略是：精准定位模型性能衰减最集中、分布偏移最显著的子集，从而为模型调优与数据更新提供第一手决策依据。特别地，子集层面的分析能够提供比全局视角更精细、更具操作性的指导。该精准定位方法可延伸至任意特征选择领域。

特征级归因实践

在生产环境中开展特征级归因，可采用以下方法：

- 针对**仅存在协变量偏移**的情形，使用 MMD+LOCO(每次排除一个协变量) 或训练随机森林区分两个数据集 (Domain Classifier) 以观测特征重要性，进行特征选择。
- 针对**概念漂移** (Concept Drift), 利用元学习器结合置换 (permutation) 变量重要性进行特征选择。
- 开发 FSDS (Feature Selection for Distribution Shift) 方法论，提供主动、可操作的特征质量退化诊断与归因工具。

基于元学习器的 OOD 量化

我们提出 **meta-learner as distance-estimator** 框架，用于量化分布漂移并进行不确定性估计。

- 该框架无需论证因果性，而是完全基于目标函数 (objective function) 对两批数据之间的距离进行量化估计。
- 基于伪结果学习器 (pseudo-outcome learner) 刻画分布漂移，侧重于概念漂移，同时兼顾协变量漂移。
- 在实时数据流中，提供样本颗粒度 OOD 量化，并基于在线 bootstrap 方法进行不确定性估计，给出置信区间或者置信带。

方法四：流式数据下的模型更新触发

假设已部署模型 $\hat{f}$ 已在生产环境上线。在流式数据设置中，新观测 $\cup_{i=1}^n \{\mathbf{X}_i, Y_i\}$ 持续到达，目标是为用户提供渐进分布偏移何时变得显著的信息——从而触发模型更新。


- 提出基于经验 p 值的程序，评估当前预测误差相对于已部署模型中预测误差的极端程度。
- 基于 online FDR control 方法来进行在线统计检验。
- **模型无关**，只要定义有效的预测模型并支持近实时推理即可。
- 重训耗时较长时，可 fallback 至影子模型或简化版模型，保障在线可用性。
- 软件开源地址：
<https://github.com/ruanhq-StatsML/OnlineRFPerm>

在线方法延伸图示

基于在线预测偏差流的分布漂移检验

When the distribution shift become significant for **already-deployed model**?


Random Forest as Reference Model



Empirical p-value

Prediction

$$P - value = (1 + \{\#MSE_{i,i=1,...,k} < MSE_{ref}\}) / (1 + k)$$



- Very Robust under High-Dimensional Covariates
- Change-Point Detection via Monitoring Predictive Performance


Flexible: Batch Setting/ Streaming Setting

图: 渐进分布偏移的流式检验 - 基于预测偏差流

在线方法延伸图示

基于在线 PO-risk 流的概念漂移检验

Can you detect concept drift or out-of-distribution(with a focus on concept drift) in the deployed ML models?




- Not Sensitive to feature dimensions, PO-risk as Distance Estimator
- Streaming Concept Drift Detection via Monitoring Distance
- Flexibility for the component model.
- Is the model performance drop comes from the concept drift or covariate shift?


图: 渐进分布偏移的流式检验 - 基于在线 PO-risk

在线方法的模态无关性

该方法论是模型无关的，并在多种数据模态上证明了有效性-使其无需修改架构即可广泛应用于任何 ML 系统。



(a) 运动规划



(b) 音频



(c) 视频流

	Train			Test	
Satellite Image (x)					
Year / Region (y)	2002 / Americas	2009 / Africa	2012 / Europe	2016 / Americas	2017 / Africa
Building / Land Type (y)	shopping mall	multi-unit residential	road bridge	recreational facility	educational institution

(d) 功能图（图像）


方法：适应分布漂移

Anomaly Detection & Distribution Shift Score as Clever Covariates

我们将在线异常检测分数 (p-value)、在线滑动窗口统计量、特征选择的平均结果 (模态间不均衡性) 以及 PO-risk 等作为协变量, 选择性地纳入模型, 以缓解模型性能因分布漂移而产生的衰减。

- 开发选择性门控机制, 根据模型性能衰减程度, 对在线特征进行选择性地纳入。
- 开发在线 OOD 量化风险机制, 对特征进行实时监测, 并决策是否对特征进行删除、修改或淘汰。

方法：适应分布漂移



图：基于新特征的分布漂移适应机制

本章概览

- 1 研究目标
- 2 方法概论
- 3 落地场景及生产价值**
- 4 未来方向与应用场景

落地场景：核心任务与诊断信号

核心任务	目标变量 Y	显著异常信号	正常波动
推理丝滑	这一跳 / 路径是否合法	推理链断裂或跳转异常	幻觉率在基线内波动
合成数据一致性	还能否作为观测样本	合成分布与真实分布偏移显著 (如 MMD 上升)	生成风格差异, 但分布未漂

注：本框架在现阶段适用于 Y 可定义、可观测且可重复的任务；对于检索等 Y 尚未明确定义的场景，暂不覆盖。

多模态归因

面向特征库与多层次指标的多模态归因

当多维特征库与指标体系出现异动时，如何将异动自动归因到下一层级，并支持逐层下钻与归因。

- 在特征库中，通过多步骤特征选择与子群精准定位，为分布漂移的子群定位提供实用价值。
- 在多模态场景中，一旦检测到性能衰减，首先归因到模态层面，再基于上一层归因结果逐层下钻，包括 token 层面，图像 patch 层面以及视频帧层面。
- 在多层次指标体系（商户、用户、订单、视频等）中，结合多层次、多步骤的特征选择与子群定位，实现快速、准实时的归因。

生产价值

从特征层面理解分布偏移

从特征与客群细分层面理解分布偏移，对生产级机器学习系统具有直接的实践价值。

- 当观测到模型性能衰减时，首要任务是定位分布漂移：先定位到具体客群，再从业务角度开展根因诊断。
- 用于特征选择的两步程序 (feature selection - post-hoc localization)，可将假设检验过程转化为可操作的特征选择机制。
- 协变量偏移与概念漂移归因程序，结合现有模型监控实践，可支持近实时的自动化特征移除与精细化根因诊断，并缩短平均检测时间 (MTTD) 与平均解决时间 (MTTR)。

应用场景

观测到模型性能衰减时，该采取何种 action？

- 由于分布漂移以及模型性能衰减的不可唯一解耦性 (impossibility issue)，模型性能的衰减无法唯一归因到特征层面，同时分布漂移也无法唯一定位归因到特征层面。故建议首先采取子群定位的方法，将分布漂移定位到子群/子集层面。
- 根据特征选择方案，将该特征的不同粒度对应的子群进行可视化以及计算子群间的分布漂移的刻度，如均值差异，MMD，PO-risk 等等。

生产价值：RFPerm-as-Judge

随机森林置换检验作为数据生成评估器

基于随机森林置换检验，构建了一个轻量的数据生成评估框架。

- **核心任务**：检测冷启动合成数据与观测数据之间的分布一致性，确保生成数据可用、可信。
- **关键优势**：仅需 **30–40 个样本**即可达到稳定功效；支持流式批次 (streaming) p 值追踪，实时监控生成质量。
- **赋能 CUPED 与 A/B 实验冷启动**：在线检测分布一致性，保障实验功效与公平性，并针对根因告警给出针对性下探方向。
- **模态无关 (Modality Agnostic)**：适用于多种数据类型与生成场景，包括 A/B 测试冷启动加速、数据增强 (Data Augmentation)，以及 LLM 反馈闭环中的生成质量评估。
- **延伸至在线学习**：该框架可进一步拓展至在线学习场景，例如基于实时数据流动态更新模型参数，或根据评估器反馈调整生成数据分布，从而实现闭环自适应优化。

生产价值：加速 A/B 实验上线流程

随机森林置换检验赋能数据的对齐和数据增强。

- 融合流式分布漂移检测与 CUPAC/CUPED：检测出显著差异后，触发重新训练流程。
- 周期性对样本特征空间进行聚类，保证数据对齐并提升信噪比，使在线实验数据能够有效适应时序分布漂移。由此有效降低估计偏差与方差，显著提升统计检验功效，缩短 A/B 实验从投放到决策的周期。
- 让中小客群在数据有限、波动频繁的冷启动和高频迭代场景中，也能具备大客群级别的稳健实验加速能力，真正实现降本增效与敏捷决策。

生产价值：在线特征重要性监控

核心问题：何时应淘汰某个特征？何时需要重新调整模型？

我们将所提出的置换特征重要性框架集成到生产级监控系统中，为已部署的机器学习模型提供实时诊断能力。**核心创新：**

- **流式置换重要性：**在滑动窗口上持续计算每个特征对当前批次预测性能的边际贡献，实现时间自适应的特征重要性评估（Incremental Permutation Feature Importance）。
- **实时看板 + 置信区间：**开发实时可视化看板，对特征重要性进行动态排序，并叠加基于自助法（*Bootstrap*）的置信区间，帮助工程师区分随机波动与真正的性能退化。
- **实时监控 PO-risk：**在同一看板中，对样本级 PO-risk（pseudo-outcome risk）及其基于在线自助法（online bootstrap）的置信区间进行排序，帮助数据科学家以更细粒度实时监控分布漂移。

生产价值：在线特征重要性监控

业务价值：该系统以统计严谨性回答多个关键运维问题：

- ① **何时弃用特征？**当某个特征的重要性置信区间在滚动窗口上持续低于预设阈值时。
- ② **何时重训模型？**当核心特征的相对排序发生显著变化，提示数据生成过程存在概念漂移（Concept Drift）时（OnlineRFPerm）。
- ③ **如何系统性地刻画 OOD？**利用元学习器刻画分布外或分布漂移程度，并对 OOD 本身进行不确定性度量。
- ④ **如何对多个系统的指标体系和特征库进行归因？**首先在图上进行子集/局部定位，再辅以 FSDS 逻辑。

生产价值：集成到生产系统

将所提出的分布偏移特征选择程序集成到生产系统中：

- 该方案结合 PO-risk(OOD) 监控，模型性能监控，特征重要性监控和在线异常检测分数监控。可无缝集成到现有模型监控流程，作为已部署上线 ML 系统中 PSI, KL 散度和 KS 统计量等常规指标的补充。
- 虽然完全无假设地识别分布偏移驱动因素不可行，但该程序仍能提取出对观测偏移有显著贡献的**前 k 个特征排序列表**，为业务、运营和工程团队提供可操作的参考。

生产价值：两类统计方法论

我们提出两个维度的统计学和机器学习方法论：**流式检验**和**批量检验**程序，具有高度通用性，可适用于多种生产场景。

- 批量检验: 置换检验可并行化, 使得每 5 分钟进行一次检验在计算上可行。流式检验的生产落地: 对流式观测 (或小批次 mini-batch 观测) 进行近实时推理和假设检验, 给出模型更新的信号。
- 高度灵活: 所有方法均可适配多种类型的数据集和模态-文本,

本章概览

- 1 研究目标
- 2 方法概论
- 3 落地场景及生产价值
- 4 未来方向与应用场景**

以下几个有前景的研究方向可自然扩展我们的框架，并有助于已部署模型持续创造价值：

- **流式监控与检测**：使用神经编码器（TarNet/DragonNet）扩展至连续微批次，用于在线流式 OOD 检测。如何解耦 OOD 本身的效应？如何在连续批次中将 OOD 归因到每一层？
- **多模态学习**：将分布漂移的模态粒度归因作为下一轮模型训练的指导，提升模型在分布偏移下的鲁棒性，从而持续产生经济效益。